

Blatt 04 – A4.4 Parser mit recursive descent

Modul: Compilerbau — Gruppe: Adrian Kramkowski, Abdelhadi Fares, Yousef Al Sahli, Abdelraoof Sahli

A4.4 – Parser (LL(1), rekursiver Abstieg)

1) Grundstruktur des Parsers

```
/**  
 * Rekursiver LL(1)-Parser für die Lisp-artige Sprache.  
 *  
 * Der Parser arbeitet auf dem Tokenstrom des Lexers aus A4.3 und  
 * überprüft, ob der Input zur Grammatik aus A4.2 passt.  
 *  
 * In A4.4 erzeugen die Methoden noch keinen AST, sondern prüfen  
 * nur die Syntax. In A4.5 wird hierauf aufgebaut.  
 */  
  
public class Parser {  
  
    private final Lexer lexer;  
    private Token lookahead; // aktuelles Lookahead-Token  
  
    public Parser(Lexer lexer) {  
        this.lexer = lexer;  
        consume(); // erstes Token laden  
    }  
  
    /**  
     * Haupteinstieg: parst ein komplettes Programm.  
     * Wenn am Ende kein EOF steht oder unterwegs ein Fehler auftritt,  
     * wird eine RuntimeException mit Fehlermeldung geworfen.  
     */  
    public void parseProgram() {  
        program();  
        match(TokenType.EOF); // Programm muss sauber mit EOF enden  
    }  
  
    // -----  
    // Hilfsfunktionen match() und consume()  
    // -----
```

```

private void match(TokenType expected) {
    if (lookahead.getType() == expected) {
        consume();
    } else {
        throw parseError(expected, lookahead);
    }
}

private void consume() {
    lookahead = lexer.nextToken();
}

private RuntimeException parseError(TokenType expected, Token found) {
    String msg = "Parser-Fehler: erwartetes Token " + expected
        + ", aber " + found.getType()
        + " (" + found.getLexeme() + ") an Position "
        + found.getLine() + ":" + found.getColumn();
    return new RuntimeException(msg);
}

private RuntimeException parseError(String message) {
    String msg = "Parser-Fehler: " + message
        + " (gefunden " + lookahead.getType()
        + " " + lookahead.getLexeme() + " an "
        + lookahead.getLine() + ":" + lookahead.getColumn() + ")";
    return new RuntimeException(msg);
}

// -----
// 2) Zu jeder Grammatikregel eine passende Methode
// -----

// -----
// program : expression_list ;
// -----
private void program() {
    expressionList();
}

// -----
// expression_list
//  : expression expression_list

```

```

// | ε
// -----
private void expressionList() {
    // FIRST(expression) = { INT, STRING, BOOL, IDENT, LPAREN }
    while (isExpressionStart(lookahead.getType())) {
        expression();
    }
    // epsilon erlaubt, daher kein Fehler, wenn nichts mehr passt
}

private boolean isExpressionStart(TokenType t) {
    switch (t) {
        case INT:
        case STRING:
        case BOOL:
        case IDENT:
        case LPAREN:
            return true;
        default:
            return false;
    }
}

// -----
// expression
// : literal
// | IDENT
// | LPAREN form RPAREN
// -----
private void expression() {
    switch (lookahead.getType()) {
        case INT:
        case STRING:
        case BOOL:
            literal();
            break;
        case IDENT:
            // Variable / Funktionsname alleine
            match(TokenType.IDENT);
            break;
        case LPAREN:
            match(TokenType.LPAREN);
            form();
    }
}

```

```

        match(TokenType.RPAREN);
        break;
    default:
        throw parseError("Unerwarteter Ausdrucksbeginn");
    }
}

// -----
// literal : INT | STRING | BOOL ;
// -----
private void literal() {
    switch (lookahead.getType()) {
        case INT:
            match(TokenType.INT);
            break;
        case STRING:
            match(TokenType.STRING);
            break;
        case BOOL:
            match(TokenType.BOOL);
            break;
        default:
            throw parseError("Literal erwartet");
    }
}

// -----
// form
// : IF expression expression opt_expression
// | DO expression_list
// | DEF IDENT expression
// | DEFN IDENT LPAREN param_list RPAREN expression
// | LET LPAREN let_bindings RPAREN expression
// | LIST expression_list_nonempty
// | NTH expression expression
// | HEAD expression
// | TAIL expression
// | function_call
//
// Der erste Token nach '(' entscheidet die Alternative.
// -----
private void form() {
    switch (lookahead.getType()) {

```

```
case IF:
    parseIfForm();
    break;
case DO:
    parseDoForm();
    break;
case DEF:
    parseDefForm();
    break;
case DEFN:
    parseDefnForm();
    break;
case LET:
    parseLetForm();
    break;
case LIST:
    parseListForm();
    break;
case NTH:
    parseNthForm();
    break;
case HEAD:
    parseHeadForm();
    break;
case TAIL:
    parseTailForm();
    break;
// Operatoren oder normaler Funktionsname
case PLUS:
case MINUS:
case TIMES:
case DIV:
case EQ:
case LT:
case GT:
case PRINT:
case STR:
case IDENT:
    functionCall();
    break;
default:
    throw parseError("Ungültige Form innerhalb von Klammern");
}
```

```
}

// -----
// if-Form: (if cond then [else])
// -----
private void parseIfForm() {
    match(TokenType.IF);
    expression();      // Bedingung
    expression();      // then-Zweig
    optExpression();   // optionaler else-Zweig
}

// opt_expression : expression | ε ;
private void optExpression() {
    if (isExpressionStart(lookahead.getType())) {
        expression();
    } else {
        // epsilon
    }
}

// -----
// do-Form: (do e1 e2 ...)
// -----
private void parseDoForm() {
    match(TokenType.DO);
    expressionList();
}

// -----
// def-Form: (def name value)
// -----
private void parseDefForm() {
    match(TokenType.DEF);
    match(TokenType.IDENT);
    expression();
}

// -----
// defn-Form: (defn name (params) body)
// -----
private void parseDefnForm() {
    match(TokenType.DEFN);
```

```

        match(TokenType.IDENT);
        match(TokenType.LPAREN);
        paramList();
        match(TokenType.RPAREN);
        expression(); // Funktionskörper
    }

// param_list : IDENT param_list_tail | ε ;
private void paramList() {
    if (lookahead.getType() == TokenType.IDENT) {
        match(TokenType.IDENT);
        paramListTail();
    } else {
        // epsilon
    }
}

// param_list_tail : IDENT param_list_tail | ε ;
private void paramListTail() {
    while (lookahead.getType() == TokenType.IDENT) {
        match(TokenType.IDENT);
    }
}

// -----
// let-Form: (let (name value ...) body)
// -----
private void parseLetForm() {
    match(TokenType.LET);
    match(TokenType.LPAREN);
    letBindings();
    match(TokenType.RPAREN);
    expression(); // body
}

// let_bindings : IDENT expression let_bindings_tail ;
private void letBindings() {
    match(TokenType.IDENT);
    expression();
    letBindingsTail();
}

// let_bindings_tail : IDENT expression let_bindings_tail | ε

```

```

private void letBindingsTail() {
    while (lookahead.getType() == TokenType.IDENT) {
        match(TokenType.IDENT);
        expression();
    }
}

// -----
// list-Form: (list e1 e2 ...)
// -----
private void parseListForm() {
    match(TokenType.LIST);
    expressionListNonEmpty();
}

// expression_list_nonempty : expression expression_list ;
private void expressionListNonEmpty() {
    expression();
    expressionList();
}

// -----
// nth-Form: (nth list-expr index-expr)
// -----
private void parseNthForm() {
    match(TokenType.NTH);
    expression(); // Listenausdruck
    expression(); // Indexausdruck
}

// -----
// head-Form: (head list-expr)
// -----
private void parseHeadForm() {
    match(TokenType.HEAD);
    expression();
}

// -----
// tail-Form: (tail list-expr)
// -----
private void parseTailForm() {
    match(TokenType.TAIL);
}

```

```

        expression();
    }

// -----
// function_call
// : operator expression_list_nonempty
// | IDENT expression_list_nonempty
// -----
private void functionCall() {
    if (isOperator(lookahead.getType())) {
        // operator-Call, z.B. (+ 1 2 3)
        match(lookahead.getType()); // PLUS/MINUS/...
        expressionListNonEmpty();
    } else if (lookahead.getType() == TokenType.IDENT) {
        // Funktionsaufruf, z.B. (foo 1 2)
        match(TokenType.IDENT);
        expressionListNonEmpty();
    } else {
        throw parseError("Funktions- oder Operatoraufruf erwartet");
    }
}

private boolean isOperator(TokenType t) {
    switch (t) {
        case PLUS:
        case MINUS:
        case TIMES:
        case DIV:
        case EQ:
        case LT:
        case GT:
        case PRINT:
        case STR:
            return true;
        default:
            return false;
    }
}
}

```

3) Nutzung des Parsers

```
public class Main {  
    public static void main(String[] args) {  
        String source = "(def x 42)\n" +  
                      "(print (+ x 1))\n";  
  
        Lexer lexer = new Lexer(source);  
        Parser parser = new Parser(lexer);  
  
        // Wirft eine Exception, falls ein Syntaxfehler auftritt:  
        parser.parseProgram();  
  
        System.out.println("Programm ist syntaktisch korrekt.");  
    }  
}
```

Der Parser folgt exakt dem in der Vorlesung gezeigten Muster: Zu jeder Grammatikregel gibt es eine Methode. Über `lookahead` und `match()` wird das nächste Token geprüft und konsumiert. Die Fehlerbehandlung gibt die Abweichung zwischen erwartetem und tatsächlich gefundenem Token mit Zeile/Spalte aus. In A4.5 können die Methoden dann so erweitert werden, dass sie statt `void` passende AST-Knoten zurückliefern.